

Rating/Scoring z Interpretowalnością, Wyjaśnialnością i Kalibracją

Barbara Jankowska, Krystian Kaliś

02.12.2025

Spis Treści

- 1 Wstęp i Cele Projektu
- 2 Eksploracja danych i tworzenie modeli
- 3 Ocena i Interpretowalność Regresji Logistycznej
- 4 Ocena i Wyjaśnialność XGBoost
- 5 Porównanie jakości i spójności wyjaśnień modeli
- 6 Kalibracja, Próg Decyzyjny, Ratingi
- 7 Końcowe Wnioski

Główne Cele Projektu

- Zaprojektowanie **systemu oceny ryzyka kredytowego** przedsiębiorstw (PD - Probability of Default).
- Budowa dwóch modeli:
 - 1 **Model Interpretowalny**: Regresja Logistyczna (stabilność i jasność decyzyjna).
 - 2 **Model "Black-Box"**: XGBoost (maksymalizacja zdolności predykcyjnej).
- **Kalibracja prawdopodobieństw** do tendencji centralnej na poziomie 4%.
- Zapewnienie **wyjaśnialności** dla obu modeli.


- **Zbiór Danych:** 3000 obserwacji, 220 zmiennych finansowych
- **Typy danych:** Głównie numeryczne, jedynie 2 kategorięczne
- **Zmienna Celu (Default):** Silnie **niezbalansowana** (duża przewaga klasy 0).
- **Obsługa Problemów Jakości (Data Quality):**
 - Konwersja wartości `inf` na `NaN`
 - Usunięcie 7 kolumn z brakami danych $> 80\%$.
 - Rozkłady: obserwacja kolumn o **niskiej wariancji** i **outlierów**.
- **Podział Danych:** Treningowy (60%), Walidacyjny (20%), Testowy (20%).

- **Preprocessing:** przycinanie outlierów, usuwanie kolumn o małej wariancji, usuwanie kolumn mocno skorelowanych, skalowanie, imputowanie braków danych, OneHotEncoding
- Pipeline'y do tworzenia modeli (Regresja Logistyczna oraz XGBoost)
- **RandomizedSearchCV** do wybierania optymalnych hiperparametrów.

Regresja logistyczna - wstępna ocena modelu

Tabela: Metryki LR (Przed Kalibracją, Próg: 0.5)

Metryka	Trening	Walid	Test	Wnioski
AUC/ROC	0.7414	0.7452	0.7471	Dobra zdolność rankowania, brak overfittingu. Umiarkowana wydajność na rzadkiej klasie. Separacja stabilna.
PR-AUC	0.2034	0.1750	0.2661	
KS	0.3506	0.4220	0.3772	
Log-Loss	0.6025	0.5981	0.5994	Wysokie → Konieczność kalibracji PD.
Brier Score	0.2091	0.2070	0.2080	
Accuracy	0.6711	0.6750	0.6650	Myląca (niezbalansowanie). Akceptowalne łapanie defaultów. Niska wiarygodność prognozy.
Recall	0.6250	0.6571	0.6923	
Precision	0.1206	0.1117	0.1250	



Współczynniki i ważność cech

- **Współczynnik (+):** Wzrost cechy zwiększa ryzyko defaultu.
- **Współczynnik (-):** Wzrost cechy ryzyko defaultu.


Tabela: Najważniejsze cechy modelu LR wg modułu wartości współczynników

Nazwa Cechy	Współczynnik	Wpływ na Ryzyko
Rozliczenia_miedzyokresowe_krotkie	-0.266	Obniża (↓)
wsk_struktura_kap_wlasnego_s_1	0.257	Zwiększa (↑)
wsk_zysk_operacyjny_zob_2	0.184	Zwiększa (↑)
wsk_koszty_przychody	-0.178	Obniża (↓)
Zysk_netto	-0.125	Obniża (↓)
wsk_rotacja_zapasow	-0.114	Obniża (↓)
wsk_sprzedaz_kap_obrotowy	0.099	Zwiększa (↑)
Wartosc_firmy	-0.087	Obniża (↓)
wsk_rotacja_aktywow_2	-0.068	Obniża (↓)
wsk_koszty_operacyjne	-0.067	Obniża (↓)

Interpretowalność Globalna Regresji Logistycznej - PDP/ICE

- ICE - wpływ od pojedynczych obserwacji, PDP - po uśrednieniu.
- monotoniczny wzrost przewidywanego PD.
- spójne, nie wykazują anomalii, stabilność modelu.

Partial Dependence Plot, Individual Conditional Expectation



Interpretacja lokalna: dekompozycja logitu dla wybranego klienta


Tabela: Dekompozycja logitu dla klienta ID = 0 ($\widehat{PD} = 0.4809$)

Cecha	Wkład (Logit)
Intercept (Wkład Bazowy)	-0.2822
wsk_struktura_kap_wlasnego	-0.2071
Rozliczenia_miedzyokresowe_krotkie	0.2041
wsk_zysk_operacyjny_zob	-0.1174
Zysk_netto	0.0900
wsk_rotacja_zapaszow	0.0829
Wartosc_firmy	0.0549
wsk_zob_oprocentowanych	-0.0494
wsk_koszty_przychody	-0.0492
wsk_rotacja_aktywow_2	0.0490
wsk_sprzedaz_kap_obrotowy	-0.0487
wsk_koszty_operacyjne	0.0429

- **Logit** = -0.0766 .
- **Wniosek:** Ocena ryzyka balansuje na granicy decyzji (PD bliskie 0.5).
- Cechy takie jak **Rozliczenia_miedzyokresowe_krotkie** oraz **Zysk_netto** istotnie podnoszą logit (ryzyko), pomimo że bazowy **Intercept** je obniża.

XGBoost - wstępna ocena modelu

Metryka	Treningowy	Walidacyjny	Testowy	Wnioski Wstępne
AUC/ROC	0.9568	0.7328	0.7447	Przeuczenie (0.95 vs 0.74). Spadek poza treningowym zbiorem. Wysoka separacja na tren., niższa na wal/test.
PR-AUC	0.6324	0.1752	0.2353	
KS	0.8190	0.4106	0.4295	
Log-Loss	0.3913	0.4361	0.4240	Wysokie wartości → Konieczność kalibracji PD.
Brier Score	0.1162	0.1364	0.1311	
Accuracy	0.8756	0.8183	0.8317	Myląca ze względu na niezbalansowanie.
Recall	0.9417	0.3714	0.3590	Spadek Recall na zbiorze treningowym testowym.
Precision	0.3424	0.1300	0.1556	Niska wiarygodność pozytywnej prognozy.




Wyjaśnialność Globalna: SHAP (Black-Box)


- **Metody Model-Agnostic** - relacja między zmianami na wejściu (dane) a wyjściu (predykcja) zamiast analizowania wewnętrznego wag modelu.
- Metoda **SHAP** - metoda Model-Agnostic, rozdziela wkład każdej cechy na wynik końcowy. Wynik to suma.

Wyjaśnialność Globalna: SHAP (Black-Box)


- **Kluczowy Predyktor:** `wsk_sprzedaz_kap_obrotowy` (relacja sprzedaży do kapitału obrotowego).
- **Wniosek Biznesowy:** Model premiuje wysoka sprzedaż przy optymalnym kapitale obrotowym i karze firmy z zamrożonym kapitałem.



(a) Summary



(b) Beeswarm



(c) Dependence


Wyjaśnialność Lokalna: LIME - klient ryzykowny

- **LIME** aproksymuje predykcję w otoczeniu pojedynczego klienta prostym modelem liniowym. Określa cechy najbardziej przyczyniające się do konkretnej predykcji.
- **Klient Ryzykowny ($\widehat{PD} \approx 80.78\%$):** Dominują **zielone cechy** (zwiększające ryzyko), np. bardzo niska sprzedaż vs kapitał obrotowy, wysoki poziom zobowiązań. .



Wyjaśnialność Lokalna: LIME - klient graniczny


- **Klient Graniczny ($PD \approx 7.45\%$):** Dominują **czerwone cechy** (zmniejszające ryzyko), np. wysoka rotacja kapitału obrotowego, dodatni zysk netto.



- Wyniki **spójne biznesowo** (zadłużenie + niska efektywność → ryzyko)

Wyjaśnialność Lokalna: What-if

- **What-if** - zmiana PD konkretnego klienta przy sztucznej zmianie wartości jednej wybranej cechy.



- logiczne zachowanie modelu: traktuje wzrost zysku operacyjnego jako czynnik obniżający ryzyko.
- stabilność modelu – nie ma sytuacji, w której "za duży zysk" nagle zwiększyłby ryzyko.

Porównanie jakości i spójności wyjaśnień modeli - globalnie

- różne strategie poznawcze modeli

Model XGBoost (SHAP)			Model Logistyczny (Coef)	
Lp.	Cecha	Waga	Cecha	Waga (Abs) Współczynnik
0	wsk_sprzedaz_kap_obrotowy	0.0438	Rozliczenia_miedzyokresowe_krotkie	0.2664 -0.2664
1	Rozliczenia_miedzyokresowe_krotkie	0.0305	wsk_struktura_kap_wlasnego_2	0.2572 0.2572
2	wsk_koszty_przychody	0.0243	wsk_zysk_operacyjny_zob_1	0.1841 0.1841
3	wsk_zysk_operacyjny_zob_1	0.0206	wsk_sprzedaz_kap_obrotowy	0.1790 -0.1790
4	koszty_sprzedazy	0.0178	Zysk_netto	0.1258 -0.1258
5	wsk_rotacja_aktywow_1	0.0170	wsk_rotacja_wartosci_niewaterialnych	0.1143 -0.1143
6	wsk_rotacja_wartosci_niewaterialnych	0.0166	wsk_zysk_op_zobowiazania	0.0994 0.0994
7	wsk_zysk_op_zobowiazania	0.0161	Wartosc_firmy	0.0878 -0.0878
8	zysk_brutto	0.0143	wsk_rotacja_aktywow_1	0.0683 -0.0683
9	wsk_liczba_dni_istnienia	0.0123	wsk_amortyzacja	0.0678 -0.0678

Porównanie jakości i spójności wyjaśnień modeli - lokalnie

- graniczny

Model XGBoost (SHAP)			Model Logistyczny (Log-Odds)	
Lp.	Cecha	Wkład	Cecha	Wkład
1	wsk_zysk_operacyjny_zob_1	0.010972	wsk_ebitda_zobowiazan_odsetki_1	0.02
2	zysk_brutto	0.003469	wsk_zob_dlugoterminowe_aktywa_rzeczowe	0.02
3	wsk_ebitda_2	0.002236	wsk_koszt_dlugu_2	0.01
4	wsk_zadluzenia_dlugie	0.001993	wsk_ebitda_2	0.00
5	Kapital_podstawowy	0.001543	wsk_struktura_majatku	-0.00



- ryzykowny

Model XGBoost (SHAP)			Model Logistyczny (Log-Odds)	
Lp.	Cecha	Wkład	Cecha	Wkład
1	Rozliczenia_miedzyokresowe_krotkie	-0.036889	Wartosc_firmy	-0.16
2	wsk_sprzedaz_kap_obrotowy	-0.030057	wsk_rotacja_wartosci_niewaterialnych	-0.25
3	wsk_koszty_przychody	-0.019666	Zysk_netto	-0.26
4	koszty_sprzedazy	-0.016703	wsk_sprzedaz_kap_obrotowy	-0.33
5	Zysk_netto	-0.013049	Rozliczenia_miedzyokresowe_krotkie	-0.54

Kalibracja - regresja logistyczna

Przed kalibracją:

- ECE (Expected Calibration Error): 0.3370
- Brier Score: 0.206994
- Reliability Error (nieskalibrowanie): 0.154972
- Krzywa reliability poniżej linii idealnej kalibracji (niedoszacowanie ryzyka)





- **Strategia Kalibracji:**

- 1 **Lokalna:** Metoda **Platt** (dla modeli logistycznych/małych prób).

- 2 **Globalna:** Dopasowanie $\overline{PD}$ do docelowego 4%.

- **Po Kalibracji:** Reliability Error ↓ do 0.001128 i Brier_Score ↓ do 0.052761 , ECE ↓ do 0.0277

- Histogram predykcji po kalibracji jest lepiej skoncentrowany przy 0%.



Optymalizacja Progu Decyzyjnego

- **Optymalizacja Progu:** Minimalizacja strat z przewagą kosztu FN ($15 \times \text{FP}$).
- **Ustalony Próg:** 0.035 (3.5%)



Rysunek

Metryki Końcowe Modelu LR

Tabela: Metryki Jakości Regresji Logistycznej (Po Kalibracji, Próg: 0.035)

Metryka	Trening	Walid	Test
AUC/ROC	0.7414	0.7452	0.7471
PR-AUC	0.2034	0.1750	0.2661
KS	0.3506	0.4220	0.3772
Log-Loss	0.2251	0.2060	0.2181
Brier Score	0.0594	0.0528	0.0574
Accuracy	0.5433	0.5400	0.5517
Recall (Czułość)	0.8167	0.8857	0.7436
Precision (Precyzja)	0.1091	0.1023	0.1007


Wnioski:

- Stabilność: AUC/ROC stabilne na wszystkich zbiorach (≈ 0.74) → brak **overfittingu**.
- Kalibracja: Niskie Brier Score i Log-Loss → kalibracja **skuteczna i stabilna**.
- Optymalizacja Kosztów: Wysoki **Recall** ($\approx 74\% - 88\%$) kosztem niskiego Precision. Zgodne z celem biznesowym (minimalizacja kosztownych False Negative).

Mapowanie na Klasy Ratingowe (LR)

- 7 Klas Ratingowych: Od AAA ($PD < 1\%$) do CCC ($PD \geq 20\%$).
- Monotoniczność średnich PD jest spełniona (średnie PD rośnie konsekwentnie z każdą gorszą klasą)

Monotoniczność Średniego PD





Rozkład Klientów

Rating	Liczba Obserwacji
AAA	96
AA	96
A	250
BBB	99
BB	38
B	17
CCC	4

Kalibracja - XGBoost

Przed kalibracją:

- ECE (Expected Calibration Error): 0.02615
- Brier Score: 0.136431
- Reliability Error (nieskalibrowanie): 0.085398
- Krzywa reliability poniżej linii idealnej kalibracji (niedoszacowanie ryzyka)





• Strategia Kalibracji:

1 **Lokalna:** Metoda **Isotonic** (lepsza dla modeli nieliniowych).


2 **Globalna:** Dopasowanie $\overline{PD}$ do docelowego 4%.

• **Po Kalibracji:** Reliability Error ↓ do 0.001236 i Brier_Score ↓ do 0.050996 , ECE ↓ do 0.0183



Optymalizacja Progu Decyzyjnego

- **Optymalizacja Progu:** Minimalizacja strat z przewagą kosztu FN ($15 \times \text{FP}$).
- **Ustalony Próg:** 0.025 (2.5%)



Rysunek

Metryki Końcowe Modelu XGBoost (Po Kalibracji)

Tabela: Metryki Jakości Modelu XGBoost (Po Kalibracji, Próg: 0.025)

Metryka	Trening	Walid	Test
AUC/ROC	0.9349	0.7685	0.7399
PR-AUC	0.4966	0.1812	0.1774
KS	0.7708	0.4106	0.4063
Log-Loss (Skal.)	0.1665	0.1959	0.2230
Brier Score (Skal.)	0.0493	0.0510	0.0579
Accuracy	0.6556	0.6217	0.6200
Recall (Czułość)	1.0000	0.8000	0.7949
Precision (Precyzja)	0.1622	0.1129	0.1235


Kluczowe Wnioski:

- Przeuczenie: Wyraźny **overfitting** (AUC Train 0.93 vs Test 0.74). Wyniki Test/Walid stabilne.
- Kalibracja: Niskie Brier Score i Log-Loss → kalibracja **skuteczna**. Kosztów: Bardzo wysoki **Recall** ($\approx 80\%$) dzięki niskiemu progowi (**0.025**), co było priorytetem.

Mapowanie na Klasy Ratingowe (LR)

- 7 Klas Ratingowych: Od AAA (PD < 1%) do CCC (PD ≥ 20%).
- Monotoniczność średnich PD jest spełniona (mimo braku obserwacji w klasie BB)

Monotoniczność Średniego PD



Rozkład Klientów

Rating	Liczba Obserwacji
AAA	117
AA	111
A	217
BBB	127
BB	0
B	22
CCC	6

- Przeuczenie XGBoost, widać w różnicach między AUC dla zbioru treningowego i testowego. Stabilna regresja logistyczna.
- Modele skalibrowano na $PD = 4\%$, osiągnięto niski błąd nieskalibrowania.
- modele skuteczne w identyfikacji ryzykownych klientów.
- Spełniona monotoniczność ratingu dla obu modeli.

- **Regresja Logistyczna:**

- **Zaleta:** Przejrzysta logika, **stabilna** globalnie i lokalnie.

- **XGBoost:**

- **Zaleta:** Wyższa precyzja, zdolność do wykrywania nieliniowych zależności.
- **Wada:** Złożona logika, trudniejsza do wytłumaczenia.

Dziękujemy za Uwagę