

Projekt 1 - Rating/scoring z interpretowalnością, wyjaśnialnością i kalibracją

Barbara Jankowska, Krystian Kaliś

Grudzień 2025

Spis treści

1	Wstęp	2
2	Eksploracja i podział danych	2
2.1	Charakterystyka Zestawu Danych	2
2.2	Data Quality	3
2.3	Podział danych	3
3	Preprocessing i pipeline	3
3.1	Implementacja Własnych Transformerów	3
3.2	Preprocessing Kategoryczny i Numeryczny	3
3.2.1	Ścieżka dla Zmiennych Numerycznych	4
3.2.2	Ścieżka dla Zmiennych Kategorycznych	4
3.3	Selekcja Cech w Pipeline Kończącym	4
4	Tworzenie i trenowanie modeli	4
4.1	Trenowanie i dobór hiperparametrów dla regresji logistycznej	4
4.2	Trenowanie i dobór hiperparametrów dla XGBoost	5
4.2.1	Siatka Parametrów i Optymalna Konfiguracja XGBoost	5
5	Ocena i interpretowalność modelu regresji logistycznej	5
5.1	Wstępna ocena modelu	5
5.1.1	Wyniki Modelu Regresji Logistycznej (Przed Kalibracją)	6
5.1.2	Wnioski	7
5.2	Współczynniki i ważność cech	7
5.3	Interpretowalność Globalna - PDP/ICE	7
6	Interpretacja lokalna: dekompozycja logitu dla wybranego klienta	8
6.1	Testy monotoniczności	9
7	Ocena i wyjaśnialność modelu XGBoost	9
7.1	Wstępna ocena modelu	9
7.2	Wnioski	10
7.3	Wyjaśnialność model-agnostic	11
7.4	SHAP	11
7.5	LIME	13
7.6	What-if	15
8	Porównanie jakości i spójności wyjaśnień modelu black-box z modelem interpretowalnym	16
9	Kalibracja, próg decyzyjny, mapowanie na ratingi - regresja logistyczna	17
9.1	Ocena modelu	17
9.1.1	Dekompozycja Brier_Score	17
9.2	Kalibracja Prawdopodobieństw (PD)	18
9.2.1	Kalibracja lokalna (Platt)	18
9.2.2	Kalibracja globalna (Calibration-in-the-large)	18
9.3	Ocena jakości po kalibracji	18

9.3.1	Stabilność per podgrupa	19
9.4	Optymalizacja Progu Decyzyjnego	19
9.5	Mapowanie PD na Klasy Ratingowe	20
9.5.1	Definicja Klas Ratingowych	20
9.5.2	Rozkład Klientów i Weryfikacja Monotoniczności	20
9.5.3	Wnioski z Mapowania	21
9.6	Ostateczna Ocena Jakości Modelu Regresji Logistycznej	22
9.6.1	Wnioski Końcowe	22
10	Kalibracja, Próg Decyzyjny, Mapowanie na Ratingi - XGBoost	23
10.1	Ocena Modelu	23
10.1.1	Dekompozycja Brier Score	23
10.2	Kalibracja Prawdopodobieństw (PD)	23
10.2.1	Kalibracja lokalna (Isotonic Regression)	23
10.2.2	Kalibracja globalna (Calibration-in-the-large)	23
10.3	Ocena Jakości Po Kalibracji	23
10.3.1	Stabilność per Podgrupa	24
10.4	Optymalizacja Progu Decyzyjnego	25
10.5	Mapowanie PD na Klasy Ratingowe	25
10.5.1	Rozkład Klientów i Weryfikacja Monotoniczności	25
10.5.2	Wnioski z Mapowania	25
10.6	Ostateczna Ocena Jakości Modelu XGBoost	26
10.6.1	Wnioski Końcowe	26
11	Końcowe wnioski	27
11.1	Porównanie Modeli i Jakości	27
11.2	Interpretowalność i Wyjaśnialność	27

1 Wstęp

Głównym celem projektu jest zaprojektowanie systemu oceny ryzyka kredytowego przedsiębiorstw. W tym celu po odpowiednio wykonanej do problemu eksploracji danych, zbudowano dwa modele:

1. Model interpretowalny, czyli Regresję Logistyczną zapewniającą stabilność i jasność decyzyjną.
2. Model „Black-box”, XGBoost, który ma na celu maksymalizację zdolności predykcyjnej.

Kluczowym etapem projektu jest kalibracja prawdopodobieństw do tendencji centralnej na 4%, co pozwala na interpretację wyników modelu jako rzeczywistego prawdopodobieństwa niewypłacalności, a nie tylko rankingu.

2 Eksploracja i podział danych

Wstępny etap projektu koncentrował się na kontroli jakości danych, zrozumieniu ich struktury oraz opracowaniu spójnej strategii preprocesingu. Wyniki te posłużyły do zdefiniowania kompletnego pipeline’u transformacji cech, który został zastosowany przed treningiem obu modeli predykcyjnych.

2.1 Charakterystyka Zestawu Danych

Zbiór danych obejmował 3000 obserwacji oraz 220 zmiennych opisujących kondycję finansową podmiotów gospodarczych. Dominującą grupę stanowiły zmienne numeryczne (218), jedynie 2 zmienne były kategoryczne.

Zmienna Celu (Target): Zdefiniowano ją jako binarną flagę **default** (zdarzenie ryzyka). Cecha ta wykazywała się nierównowagą klas (obserwacje negatywne - 0) stanowią zdecydowaną większość, co jest typowe dla problemów scoringowych w sektorze finansowym.

2.2 Data Quality

W ramach kontroli jakości danych zidentyfikowano i obsłużono następujące problemy:

- **Wartości nieskończone:** Wiele wskaźników finansowych, ze względu na zerowe wartości w mianownikach, generowało wartości inf (nieskończoność). Zostały one zamienione wartości NaN, aby umożliwić ich późniejszą imputację.
- **Braki Danych:** Podczas analizy braków danych znaleźliśmy 7 kolumn, których brakowało **ponad 80%** obserwacji. Zostały one usunięte ze zbioru danych. Pozostałe braki danych w zmiennych numerycznych były później uzupełniane medianami w preprocessingu.
- **Rozkłady zmiennych:** Zwizualizowaliśmy rozkłady danych za pomocą histogramów. Dało się zauważyć, że wiele zmiennych ma bardzo małą wariancję, mają prawie same stałe wartości. Ponadto dało się zaobserwować wartości odstające (outliery) dla niektórych zmiennych. Na późniejszym etapie, w preprocessingu, kolumny o bardzo małej wariancji zostaną usunięte, a outliery przycięte.
- **Korelacje:** Zbadaliśmy korelację dwóch kolumn kategorycznych: *schemat_wsk_bilans* i *schemat_wsk_rzis* (już po podziale na train/val/test). Zgodność cech wyszła bardzo wysoka (**98%**), zatem jedną z nich usuwamy. Inne korelacje między kolumnami oraz z targetem zostaną przeprowadzone już w preprocessingu i pipeline, mocno skorelowane kolumny zostaną usunięte.

2.3 Podział danych

Dane zostały podzielone na trzy zbiory: treningowy (**60%**), walidacyjny (**20%**) i testowy (**20%**). Użyliśmy `random_state = 123`

Podczas trenowania modeli będziemy korzystać z krosvalidacji wbudowanej w metodę `RandomSearchCV`, zatem zbiór walidacyjny przyda się przede wszystkim do kalibracji oraz oceny modeli.

3 Preprocessing i pipeline

Aby zapewnić reprodukowalność, spójność transformacji i uniknąć wycieku danych, w projekcie zaimplementowano proces przygotowania danych w architekturze **Pipeline** z biblioteki *scikit-learn*. Kluczowe kroki preprocessingu zostały zdefiniowane jako niestandardowe klasy, które uczą się parametrów transformacji wyłącznie na zbiorze treningowym.

3.1 Implementacja Własnych Transformerów

Z uwagi na specyfikę danych (duża liczba outlierów, cech o niskiej wariancji, silne korelacje), zdefiniowano trzy niestandardowe klasy transformujące:

- **OutlierCapper:** Klasa ta implementuje politykę przycinania (capping) wartości odstających w zmiennych numerycznych. Granice przycięcia (minimalna i maksymalna) są obliczane na podstawie metody IQR (kwartył Q1 i Q3 oraz mnożnik 1.5). Granice są uczone na zbiorze treningowym i następnie stosowane konsekwentnie na zbiorach walidacyjnym i testowym.
- **LowVarianceRemover:** Transformator odpowiedzialny za eliminację cech, których wariancja na zbiorze treningowym jest poniżej ustalonego progu (`min_var=10-5`). Ma to na celu usunięcie zmiennych, które są prawie stałe i nie wnoszą wartości informacyjnej do modelu.
- **HighCorrelationRemover:** Ta klasa służy do badania korelacji między cechami. Dla każdej pary, której korelacja przekracza próg 0.95, usuwana jest ta, która ma mniejszą wariancję.
- **WoEBinningTransformer:** Jest to transformator potrzebny dla modelu interpretowalnego (regresji logistycznej). Klasa ta wykonuje dwa kroki naraz:
 1. **Binning:** Dzieli zmienne na optymalne koszyki (bins).
 2. **WoE (Weight of Evidence):** Zamienia każdą kategorię (koszyk) na wartość WoE, która jest logarytmem ilorazu szans (odds) dobrych do złych klientów w danym koszyku.

3.2 Preprocessing Kategoryczny i Numeryczny

Dla obu typów zmiennych (numerycznych i kategorycznych) zdefiniowano odrębne ścieżki transformacji za pomocą `ColumnTransformer`.

3.2.1 Ścieżka dla Zmiennych Numerycznych

Ścieżka numeryczna (*numeric_transformer*) dla obu modeli była taka sama:

1. Zastosowanie wcześniej opisanych niestandardowych Transformerów: *LowVarianceRemover*, *HighCorrelationRemover* i *Outlier Capping*
2. **Imputacja:** Uzupełnienie pozostałych braków danych medianą za pomocą *SimpleImputer*.
3. **Skalowanie** za pomocą *StandardScaler*.

3.2.2 Ścieżka dla Zmiennych Kategorycznych

- **Dla XGBoost:** Zastosowano imputację modą (`SimpleImputer(strategy='most_frequent')`) oraz kodowanie **One-Hot Encoding**.
- **Dla Regresji Logistycznej:** Zastosowano imputację modą oraz transformację **Weight of Evidence (WoE)** za pomocą klasy *WoEBinningTransformer*.

3.3 Selekcja Cech w Pipeline Końcowym

Na końcowym etapie pipeline'u (po wszystkich transformacjach i przed tworzeniem modeli) zastosowano jeszcze dwa mechanizmy selekcji cech:

1. **VarianceThreshold (Usuwanie Zerowej Wariancji):** Filtruje cechy, które po przetworzeniu (np. po One-Hot Encoding) stały się stałe (wariancja równa 0).
2. **SelectFpr:** Jest to filtr oparty na testach statystycznych. Wybiera cechy, które są statystycznie istotnie skorelowane ze zmienną celu, kontrolując wskaźnik fałszywych odkryć (FPR) na poziomie $\alpha = 0.15$. Zapewnia to, że do modelu trafiają tylko te cechy, które mają moc predykcyjną.

4 Tworzenie i trenowanie modeli

Oba modele predykcyjne - model interpretowalny (**Regresja Logistyczna**) oraz model "black-box" (**XGBoost**) - zostały osadzone w pipeline'ach, które zawierają zdefiniowane wcześniej kroki preprocessingu i selekcji cech.

4.1 Trenowanie i dobór hiperparametrów dla regresji logistycznej

Do efektywnego wyszukiwania optymalnych hiperparametrów wykorzystano **RandomizedSearchCV** na 50 iteracjach z walidacją krzyżową (**CV = 3**), maksymalizując metrykę **AUC/ROC**. Testowano różne typy regularyzacji (L1, L2, ElasticNet) oraz solvery (liblinear, saga, lbfgs). Ze względu na silne niezbalansowanie klas, kluczowe było użycie parametru `class_weight='balanced'`.

Siatka parametrów dla **RandomizedSearchCV** obejmowała:

Tabela 1: Siatka Hiperparametrów dla Regresji Logistycznej (RandomizedSearchCV)

Parametr	Testowane Wartości
<code>penalty</code>	L2, L1, ElasticNet
<code>solver</code>	<code>lbfgs</code> , <code>liblinear</code> , <code>saga</code>
<code>C</code> (Odwrotność siły regularyzacji)	[0.01, 0.05, 0.1, 0.5, 1, 5, 10]
<code>l1_ratio</code> (Tylko dla ElasticNet)	[0.1, 0.3, 0.5, 0.7, 0.9]
<code>class_weight</code>	<code>balanced</code> (Stała wartość)
<code>max_iter</code>	[1000, 3000]

Uzyskaliśmy optymalny model o poniższych hiperparametrach:

Tabela 2: Optymalne Hiperparametry Regresji Logistycznej

Parametr	Wartość
<code>model__penalty</code>	<code>elasticnet</code>
<code>model__solver</code>	<code>saga</code>
<code>model__C</code> (Siła regularyzacji)	0.01
<code>model__l1_ratio</code> (Udział L1)	0.3
<code>model__max_iter</code>	3000
<code>model__class_weight</code>	<code>balanced</code>

4.2 Trenowanie i dobór hiperparametrów dla XGBoost

Do optymalizacji hiperparametrów wykorzystano ponownie **RandomizedSearchCV** na 50 iteracjach z walidacją krzyżową (**CV = 3**), maksymalizując metrykę **AUC/ROC**. Kluczowym elementem było dostosowanie modelu do silnie niezbalansowanych danych. Zastosowano parametr `scale_pos_weight`, który koryguje błąd dla rzadkiej klasy. Jego wartość została obliczona jako stosunek liczby obserwacji negatywnych do pozytywnych. Ponadto badamy również parametry (`max_depth`), (`min_child_weight`) oraz parametry próbkowania (`subsample`, `colsample_bytree`).

4.2.1 Siatka Parametrów i Optymalna Konfiguracja XGBoost

Siatka parametrów dla **RandomizedSearchCV** obejmowała:

Tabela 3: Siatka Hiperparametrów dla XGBoost (RandomizedSearchCV)

Parametr	Testowane Wartości
<code>n_estimators</code>	[100, 200, 300]
<code>max_depth</code>	[3, 4, 5, 6]
<code>learning_rate</code>	[0.01, 0.05, 0.1]
<code>min_child_weight</code>	[10, 20, 30]
<code>gamma</code> (Minimalna redukcja straty do podziału)	[0, 0.1, 0.5, 1]
<code>subsample</code> (Próbkowanie wierszy)	[0.7, 0.8, 0.9]
<code>colsample_bytree</code> (Próbkowanie kolumn)	[0.7, 0.8, 0.9]
<code>scale_pos_weight</code>	[14.0] (Stała wartość)

Optymalne Parametry XGBoost: Otrzymaliśmy model o następującym zestawie hiperparametrów:

Tabela 4: Optymalne Hiperparametry Modelu XGBoost

Parametr	Wartość
<code>model__scale_pos_weight</code>	14.0
<code>model__n_estimators</code>	200
<code>model__max_depth</code>	5
<code>model__learning_rate</code>	0.01
<code>model__gamma</code>	1
<code>model__subsample</code>	0.7
<code>model__colsample_bytree</code>	0.8
<code>model__min_child_weight</code>	20

5 Ocena i interpretowalność modelu regresji logistycznej

5.1 Wstępna ocena modelu

Wstępna ocena jakości modelu Regresji Logistycznej została przeprowadzona na surowych prawdopodobieństwach (*y_proba*), z domyślnym progiem decyzyjnym **0.5**. Jej celem było zrozumienie zdolności modelu do rankowania oraz zdiagnozowanie problemów z kalibracją prawdopodobieństw.


- **AUC/ROC:** Mierzy zdolność do rankowania, czyli jak dobrze model oddziela ryzyko od bezpieczeństwa
- **PR-AUC (Precision-Recall Area Under the Curve):** Mierzy zdolność do rankowania klientów, koncentrując się na rzadkiej klasie ryzyka (**Default**), co daje realistyczny obraz wydajności
- **KS (Kolmogorov-Smirnov):** Mierzy maksymalną separację między rozkładami ryzyka a bezpieczeństwa
- **Log-Loss (Logarytmiczna Strata):** Kara za niepewne lub błędne predykcje prawdopodobieństw (im mniejsza, tym lepiej)
- **Brier Score:** Mierzy całkowity błąd w przewidywaniu prawdopodobieństw (im mniejszy, tym lepiej). Może być mylące w przypadku niezbalansowanych klas.
- **Recall (Czułość):** Mierzy skuteczność wykrywania ryzyka; odsetek poprawnie złapanych defaultów. W przypadku tego projektu, jest to nasz priorytet (wyłapywanie ryzykownych klientów).
- **Precision (Precyzja):** Mierzy wiarygodność pozytywnej prognozy; jak często model ma rację, gdy klasyfikuje klienta jako ryzykowny. Może osiągać małe wartości na rzecz dużych wartości Recall.

5.1.1 Wyniki Modelu Regresji Logistycznej (Przed Kalibracją)

W tabeli przedstawiono wartości metryk dla Regresji Logistycznej, uzyskane z kodem `metryki(y_train, y_proba_train_lr, 0.5)`.

Tabela 5: Metryki Jakości Modelu Regresji Logistycznej (Przed Kalibracją, Próg: 0.5)

Metryka	Treningowy	Walidacyjny	Testowy	Wnioski Wstępne
AUC/ROC	0.7414	0.7452	0.7471	Dobra zdolność rankowania, brak overfittingu.
PR-AUC	0.2034	0.1750	0.2661	Umiarkowana wydajność na rzadkiej klasie.
KS	0.3506	0.4220	0.3772	Separacja na stabilnym poziomie.
Log-Loss	0.6025	0.5981	0.5994	Wysokie wartości → Konieczność kalibracji PD.
Brier Score	0.2091	0.2070	0.2080	
Accuracy	0.6711	0.6750	0.6650	Myląca ze względu na niezbalansowanie.
Recall	0.6250	0.6571	0.6923	Akceptowalne łapanie defaultów przy progu 0.5.
Precision	0.1206	0.1117	0.1250	Niska wiarygodność pozytywnej prognozy.



Rysunek 1: Krzywa ROC dla modelu Regresji logistycznej.

5.1.2 Wnioski

- **Stabilność i Overfitting:** Wartości AUC/ROC są stabilne na wszystkich zbiorach (treningowy ≈ 0.74 , walidacyjny ≈ 0.74 , testowy ≈ 0.74) Wskazuje to, że model jest dobrze uogólniony i nie wykazuje przeuczenia.
- **Kalibracja Probabilistyczna:** Metryki **Log-Loss** i **Brier Score** są zdecydowanie za wysokie Jest to silny sygnał, że surowe prawdopodobieństwa predykcyjne modelu muszą zostać skalibrowane.

5.2 Współczynniki i ważność cech

Dane testowe zostały przetworzone przez pipeline, co zredukowało liczbę kolumn do 52.

Wartość współczynników modelu (coef_) regresji logistycznej możemy interpretować jako:

- Wartość dodatnia (+): Wzrost wartości tej cechy zwiększa prawdopodobieństwo klasy pozytywnej.
- Wartość ujemna (-): Wzrost wartości tej cechy zmniejsza prawdopodobieństwo klasy pozytywnej (czyli "chroni" przed zdarzeniem "1").

Poniżej w tabeli zestawiono cechy o największym wpływie na decyzję modelu (na podstawie wartości bezwzględnej współczynnika).

Tabela 6: Najważniejsze cechy modelu regresji logistycznej wg modułu wartości współczynników

Lp.	Nazwa Cechy	Współczynnik	Kierunek Wpływu
1	Rozliczenia_miedzyokresowe_krotkie	-0.266	Negatywny (obniża ryzyko)
2	wsk_struktura_kap_wlasnego_s_1	0.257	Pozytywny (zwiększa ryzyko)
3	wsk_zysk_operacyjny_zob_2	0.184	Pozytywny
4	wsk_koszty_przychody	-0.178	Negatywny
5	Zysk_netto	-0.125	Negatywny
6	wsk_rotacja_zapaszow	-0.114	Negatywny
7	wsk_sprzedaz_kap_obrotowy	0.099	Pozytywny
8	Wartosc_firmy	-0.087	Negatywny
9	wsk_rotacja_aktywow_2	-0.068	Negatywny
10	wsk_koszty_operacyjne	-0.067	Negatywny

Współczynniki mówią nam, jak wygląda "wzór" modelu. Cecha z dużą wagą mocno przesuwają wynik.

Inną metodą badania ważności cech jest Permutation Importance. Ta metoda testuje model w praktyce. Algorytm bierze jedną cechę, losowo miesza jej wartości w zbiorze walidacyjnym (niszcząc informację, którą niesie), a następnie sprawdza, jak bardzo spadła jakość modelu. Z permutation importance skorzystano w kolejnej części oceny modelu regresji logistycznej.


Podsumowując:

- Współczynniki mówią: "Jaki jest kierunek zależności?" (np. wyższe koszty to gorzej). Służą do interpretacji zjawiska.
- Permutation Importance mówi: Które cechy są niezbędne dla jakości prognozy?. Służy do selekcji cech, bez których model przestaje działać.

5.3 Interpretowalność Globalna - PDP/ICE

W celu oceny globalnej interpretowalności modelu regresji logistycznej zostały wygenerowane wykresy PDP oraz ICE dla trzech najważniejszych cech według permutation importance. Wyniki dla wybranej losowo ze zbioru treningowego próbki 500 obserwacji przedstawione zostały na rysunku 2. Permutation importance (ważność permutacyjna) to model-agnostyczna metoda oceny ważności cech, która mierzy jak bardzo pogarsza się jakość modelu, gdy celowo niszczymy informację w jednej zmiennej.

PDP pokazuje średni wpływ jednej zmiennej x_j na przewidywaną wartość modelu (uśrednione po wszystkich innych zmiennych), czyli prezentuje wpływ cech na ryzyko PD. ICE pokazuje wpływ tej zmiennej od pojedynczych obserwacji.



Rysunek 2: PDP oraz ICE dla regresji logistycznej.

W modelu dążymy do tego, aby PD odpowiadało rzeczywistości — było dobrze skalibrowane względem danych.

Dla zmiennych *wsk_koszty_fin_przychody* oraz *wsk_zadluzenia* obserwujemy silny, monotoniczny wzrost przewidywanego PD, czyli prawdopodobieństwa defaultu, wraz ze wzrostem wartości wskaźnika, co jest zgodne z intuicją ekonomiczną: większe obciążenie finansowe i większy poziom zadłużenia zwiększają ryzyko niewypłacalności.

Trzecia cecha, *wsk_struktura_kap_obcego_s*, wykazuje umiarkowany, stabilny wpływ, z niewielką, ale dodatnią zależnością PD od udziału kapitału obcego.

Przebiegi ICE są relatywnie spójne i nie wykazują anomalii, co potwierdza stabilność modelu oraz zgodność kierunku wpływu z założeniami biznesowymi. PDP/ICE stanowią jeden z elementów wyjaśnialności modelu i potwierdzają jego transparentność.

Wykresy Partial Dependence (PDP) oraz Individual Conditional Expectation (ICE) względem zmiennych wejściowych dla modelu regresji logistycznej wychodzą liniowe. Jest to zgodne z oczekiwaniami, ponieważ regresja logistyczna jest liniowa względem logitu prawdopodobieństwa, który jest przekształcany funkcją sigmoidalną do postaci prawdopodobieństwa. Liniowy kształt PDP/ICE w logitach potwierdza poprawne działanie modelu.

6 Interpretacja lokalna: dekompozycja logitu dla wybranego klienta

Analizie poddano obserwację o indeksie równym 0. Dla tego klienta model oszacował prawdopodobieństwo niewypłacalności na poziomie

$$\widehat{PD} = 0.4809,$$

co odpowiada wartości logitu równej -0.0766.

Poniższa tabela przedstawia dekompozycję logitu na wkłady poszczególnych cech. Wartości dodatnie zwiększają logit (i tym samym PD), a ujemne go obniżają.

Tabela 7: Dekompozycja logitu dla klienta walidacyjnego ID = 0

Cecha	Wkład (Coefficient)
Intercept	-0.2822
wsk_struktura_kap_wlasnego_s_1	-0.2071
Rozliczenia_miedzyokresowe_krotkie	0.2041
wsk_zysk_operacyjny_zob_2	-0.1174
Zysk_netto	0.0900
wsk_rotacja_zapaszow	0.0829
Wartosc_firmy	0.0549
wsk_zob_oprocentowanych	-0.0494
wsk_koszty_przychody	-0.0492
wsk_rotacja_aktywow_2	0.0490
wsk_sprzedaz_kap_obrotowy	-0.0487
wsk_koszty_operacyjne	0.0429

Klient został prawidłowo sklasyfikowany jako niewymagający alertu (TN), ale poziom ryzyka wyliczony przez model – ok. 48% – jest bardzo wysoki jak na przypadek bezdefaultowy. To typowy sygnał słabej kalibracji: model nie potrafi właściwie odwzorować poziomu absolutnego ryzyka, mimo że kierunek predykcji jest poprawny.

Lokalna dekompozycja logitu (-0.0766) potwierdza, że ocena ryzyka balansuje na granicy decyzji. (Logit=0 oznacza PD = 0.5 w przypadku domyślnego proggu. Tutaj logit jest blisko 0, ale już na minusie, zgadza się z tym, że PD=48%). Bazowy wkład (Intercept = -0.2822) obniża ryzyko, natomiast kilka cech istotnie je podnosi – w szczególności: Rozliczenia_miedzyokresowe_krotkie, Zysk_netto, wsk_rotacja_zapaszow.

6.1 Testy monotoniczności

Testy monotoniczności są kluczowym etapem walidacji modeli ryzyka kredytowego. Celem analizy jest weryfikacja, czy istnieje logiczna i stała relacja między wartością danej cechy (zmiennej objaśniającej) a przewidywanym prawdopodobieństwem niewypłacalności PD. Test monotoniczności wykonamy dla regresji logistycznej.

W modelowaniu ryzyka oczekujemy zazwyczaj relacji monotonicznych. Przykładowo:

- Im wyższy dochód, tym niższe ryzyko (monotoniczność malejąca).
- Im wyższe zadłużenie, tym wyższe ryzyko (monotoniczność rosnąca).

Brak monotoniczności utrudnia interpretację modelu i może sugerować, że model przeucza się na szumie w danych, zamiast wykrywać trwałe trendy.

W celu sprawdzenia monotoniczności podzielono zmienne ciągłe na dyskretne wartości (binning). Dla każdego koszyka obliczono średnią wartość predykcji. Algorytm sprawdza różnice między średnim PD w kolejnych koszykach. Wyróżniamy:

- Test Rosnący: Sprawdza, czy każdy kolejny koszyk ma PD wyższe lub równe poprzedniemu.
- Test Malejący: Sprawdza, czy każdy kolejny koszyk ma PD niższe lub równe poprzedniemu.

Cecha jest uznana za monotoniczną, jeśli spełnia warunki trendu rosnącego LUB malejącego. W tabeli 7 przedstawiono wyniki testu monotoniczności dla naszych danych.

Możemy zauważyć, że tylko jedna cecha z 10 jest monotoniczna, zatem nasz model nie wykazuje praktycznie monotoniczności.

7 Ocena i wyjaśnialność modelu XGBoost

7.1 Wstępna ocena modelu


Wstępna ocena jakości modelu XGBoost została przeprowadzona na surowych prawdopodobieństwach (*y-proba*), z domyślnym progiem decyzyjnym 0.5.

Tabela 8: Monotoniczność zmiennych

Cecha	Monotoniczność	Kierunek_Rosnący	Kierunek_Malejący
Rozliczenia_miedzyokresowe_krotkie	NIE	NIE	NIE
wsk_struktura_kap_wlasnego_s_1	NIE	NIE	NIE
wsk_zysk_operacyjny_zob_2	NIE	NIE	NIE
wsk_koszty_przychody	NIE	NIE	NIE
Zysk_netto	NIE	NIE	NIE
wsk_rotacja_zapaszow	NIE	NIE	NIE
wsk_sprzedaz_kap_obrotowy	NIE	NIE	NIE
Wartosc_firmy	TAK	NIE	TAK
wsk_rotacja_aktwowow_2	NIE	NIE	NIE
wsk_koszty_operacyjne	NIE	NIE	NIE

Tabela 9: Metryki Jakości Modelu XGBoost (Przed Kalibracją, Próg: 0.5)

Metryka	Treningowy	Walidacyjny	Testowy	Wnioski Wstępne
AUC/ROC	0.9568	0.7328	0.7447	Przeuczenie (0.95 vs 0.74).
PR-AUC	0.6324	0.1752	0.2353	Spadek poza treningowym zbiorem.
KS	0.8190	0.4106	0.4295	Wysoka separacja na tren., niższa na wal/test.
Log-Loss	0.3913	0.4361	0.4240	Wysokie wartości → Konieczność kalibracji PD.
Brier Score	0.1162	0.1364	0.1311	
Accuracy	0.8756	0.8183	0.8317	Myląca ze względu na niezbalansowanie.
Recall	0.9417	0.3714	0.3590	Spadek Recall na zbiorze treningowym testowym.
Precision	0.3424	0.1300	0.1556	Niska wiarygodność pozytywnej prognozy.



Rysunek 3: Krzywa ROC dla modelu XGBoost.

7.2 Wnioski

- **Przeuczenie:** Wyraźna różnica między AUC na zbiorze treningowym (**0.9568**) a walidacyjnym/testowym (≈ 0.74) wskazuje na **silny overfitting** (przeuczenie). Mimo to, wyniki na zbiorach walidacyjnym i testowym są do siebie zbliżone i stabilne.
- **Kalibracja Probabilistyczna:** Wartości **Log-Loss** (≈ 0.43) i **Brier Score** (≈ 0.13) są wysokie. Jest to silny sygnał, że surowe prawdopodobieństwa predykcyjne modelu muszą zostać skalibrowane.
- **Recall:** Niski wynik **Recall** (≈ 0.37) na zbiorze walidacyjnym i testowym jest konsekwencją

overfittingu i domyślnego progu 0.5. Ten problem może zostać częściowo rozwiązany rozwiązany poprzez późniejszą kalibrację i optymalizację progu decyzyjnego.


7.3 Wyjaśnialność model-agnostic

Modele "black box" są skonstruowane tak, że mają osiągać Wysoką skuteczność predykcyjną. Trudno więc o czytelność tego modelu. Problem ten rozwiązuje podejście model-agnostic, które zamiast analizować wewnętrzne wagi modelu, bada relacje między zmianami na wejściu (dane) a wyjściem (predykcja). Pozwala to na zaufanie decyzjom algorytmu poprzez zrozumienie sterujących nim czynników, niezależnie od jego architektury. Metody, które wykorzystują podejście model-agnostic to między innymi SHAP, LIME oraz „what-if”. Wykonujemy je na danych przed kalibracją, żeby zrozumieć co model myśli o danych zanim zostaną one wygładzone przez kalibrację. W dalszej części przedstawiono zastosowanie podejścia model-agnostic w naszym problemie.

7.4 SHAP


SHapley Additive exPlanations to metoda, która pozwala sprawiedliwie rozdzielić wkład każdej cechy w wynik końcowy. Wartości SHAP są addytywne – suma wszystkich wpływów cech oraz wartości bazowej (średniej predykcji) równa się wartości przewidywanej przez model. W rozpatrywanym problemie rozważono następujące implementacje SHAP:

1. **summary plot** – umożliwia ocenę globalnego wpływu poszczególnych cech na predykcje modelu, pozwalając szybko zidentyfikować najważniejsze zmienne oraz kierunek ich oddziaływania. Otrzymany dla naszych danych wynik przedstawiono na rysunku 4.




Rysunek 4: SHAP summary plot dla modelu XGBoost.

2. **beeswarm plot** – rozszerza analizę, którą przeprowadza summary plot, prezentując rozrzut wartości SHAP dla każdej obserwacji, co pozwala wychwycić przypadki nietypowe oraz zmienność wpływu cech. W naszym przypadku beeswarm pokazano na rysunku 5.



Rysunek 5: SHAP beeswarm plot dla modelu XGBoost.

3. **dependence plot** – służy do badania zależności pomiędzy wartością cechy a jej wpływem na predykcję, umożliwiając jednocześnie analizę potencjalnych interakcji między cechami. Rysunek 6 ukazuje naszą implementację tej zależności.



Rysunek 6: SHAP dependence plot dla modelu XGBoost.

Zastosowanie tych narzędzi zapewnia kompleksową interpretację wyników modelu, zarówno w ujęciu globalnym, jak i lokalnym.

Z analizy ważności cech (SHAP Global) możemy wyciągnąć następujące wnioski:

1. Model zidentyfikował efektywność zarządzania kapitałem obrotowym jako absolutnie kluczowy predyktor ryzyka. Lider (*wsk_sprzedaz_kap_obrotowy*): Najważniejszą zmienną jest relacja sprzedaży do kapitału obrotowego. Oznacza to, że model premiuje firmy, które generują wysoką sprzedaż przy zaangażowaniu optymalnych zasobów. Jest to miara sprawności operacyjnej.
Co to oznacza biznesowo? Dla modelu ważniejsze od tego, "ile firma ma majątku", jest to, "jak sprawnie tym majątkiem obracają". Firmy z zamrożonym kapitałem (zatory płatnicze, zalegające zapasy) są oceniane jako bardziej ryzykowne.
2. Kierunek wpływu (Beeswarm Plot) Analizując rozkład punktów dla lidera (*wsk_sprzedaz_kap_obrotowy*): Wysoka efektywność (Czerwone punkty): Zazwyczaj znajdują się po lewej stronie (ujemny SHAP).
Wniosek: Firmy, które efektywnie wykorzystują kapitał obrotowy (wysoki wskaźnik), otrzymują niższą ocenę ryzyka PD. Model nagradza płynność operacyjną.
Niska efektywność (Niebieskie punkty): Znajdują się po prawej stronie.
Wniosek: Niski obrót kapitałem (czyli np. pieniądze zamrożone w niesprzedanych towarach lub u dłużników) jest silnym sygnałem ostrzegawczym, drastycznie podnoszącym przewidywane ryzyko upadłości.
3. Profil modelu ma charakter efektywnościowy. W odróżnieniu od prostych modeli bazujących tylko na zadłużeniu, ten XGBoost nauczył się wyłapywać subtelniejsze problemy operacyjne. Jeśli kapitał obrotowy firmy stoi w miejscu (*wsk_sprzedaz_kap_obrotowy* niski), model słusznie podniesie alarm przed potencjalną utratą płynności.

7.5 LIME

W rozpatrywanym problemie rozważono również implementację Local Interpretable Model-agnostic Explanations. Metoda ta umożliwia lokalną interpretację predykcji modelu poprzez aproksymację jego zachowania w otoczeniu konkretnej obserwacji za pomocą prostego, łatwego do zrozumienia modelu liniowego. Dzięki temu możliwe jest określenie, które cechy w największym stopniu przyczyniły się do konkretnej predykcji oraz w jaki sposób wpływają na wynik. LIME pozwala również na wizualizację tych zależności, co ułatwia analizę przypadków nietypowych i komunikację wyników modelu osobom nietechnicznym. Zastosowanie LIME w połączeniu z analizą globalną modeli pozwala na pełniejszą interpretację zarówno pojedynczych predykcji, jak i ogólnych wzorców w danych.

W rozpatrywanym problemie LIME, czyli metoda działająca lokalnie, zostało użyte by zinterpretować predykcję dwóch klientów zachowujących się skrajnie różnie. A mianowicie wzięto pod uwagę:

- Klienta Granicznego (Borderline) – PD = 7.45%
- Klienta Ryzykowny (High Risk) – PD = 80.78%


Analizujemy wpływ na predykcje modelu 10 najważniejszych cech dla tych dwóch konkretnych klientów. Każdy wykres to zatem zestawienie cech modelu oraz wartości, które te cechy przyjmują dla danego klienta oraz ich wpływ na wynik (czy przesuwają predykcję w stronę Spłaca (0), czy Default (1)). Na rysunkach 7 i 8 pokazano wykresy LIME odpowiednio dla klienta ryzykownego oraz granicznego.

Interpretacja osi:


- Lewo → zmniejsza ryzyko defaultu / zwiększa szansę spłaty, Czerwone cechy popychają w kierunku spłaty (0)
- Prawo → zwiększa ryzyko defaultu, zielone cechy popychają w kierunku defaultu (1)

Interpretacja zachowania poszczególnych klientów przez model:

- Klient Graniczny (Borderline), PD = 7.45% – model uważa, że klient najprawdopodobniej spłaci. Mamy następujące cechy negatywnie wpływające na default (czerwone), czyli zmniejszające ryzyko defaultu:
 - wysoka rotacja kapitału obrotowego,
 - wysoka rotacja aktywów niematerialnych,



Rysunek 7: LIME dla klienta ryzykownego.



Rysunek 8: LIME dla klienta granicznego.

- dodatni zysk netto,
- korzystne wskaźniki kosztów vs przychody,
- długoterminowe zobowiązania rzeczowe,
- niska wartość operacyjna zysku.

Pozytywne cechy dominują.

- Klient Ryzykowny (High Risk) PD = 80.78% – model ocenia wysokie ryzyko.

Najsilniejsze czynniki zwiększające ryzyko defaultu:


- bardzo niska sprzedaż w stosunku do kapitału obrotowego,
- wysoki poziom długoterminowych zobowiązań,
- słaba rotacja aktywów,
- niska struktura kapitału własnego,
- wysoki koszt sprzedaży vs przychody.

To logiczne biznesowo: firma z dużym zadłużeniem i niską rotacją aktywów jest bardziej ryzykowna.

Jedyna cecha, która „ciągnie w stronę bezpieczeństwa”, to wysoki wskaźnik zysku operacyjnego zobowiązań. Ale jej siła jest zbyt mała, aby przeciwdziałać negatywowym.

7.6 What-if

What-if to narzędzie pozwalające na interaktywną analizę modelu poprzez modyfikację wartości cech w wybranych obserwacjach i obserwowanie, jak zmieniają się predykcje. Dzięki temu można badać wrażliwość modelu na poszczególne cechy, analizować scenariusze hipotetyczne oraz identyfikować potencjalne błędy lub nieoczekiwane zachowania modelu. What-If umożliwia również wizualizację zależności między cechami a wynikami predykcji, co wspiera zarówno lokalną interpretację pojedynczych przypadków, jak i szerszą analizę danych. Zastosowanie tego narzędzia zwiększa przejrzystość działania modelu i ułatwia podejmowanie decyzji na podstawie wyników uczenia maszynowego. Na rysunku 9 pokazano analizę What-If dla klienta o wyjściowym PD wynoszącym 7.45%. Badano zachowanie pod wpływem zmian najważniejszej według tego modelu cechy *wsk_sprzedaz_kap_obrotowy*.



Rysunek 9: Analiza what-if dla modelu XGBoost dla zmiennej *wsk_sprzedaz_kap_obrotowy*.

Analiza "What-If" na surowym modelu jest bezużyteczna, bo nigdy nie przetnie linii celu, ponieważ najniższe PD dla jakiegoś klienta wynosi 7,45%. SHAP i LIME robi się przed kalibracją, bo one mają wyjaśnić model, a nie kalibrację modelu. What-if można robić na modelu przed kalibracją, ponieważ ta zmieni jedynie mapowanie, kształt zależności między cechą a wynikiem będzie ten sam. Zatem robienie samego what-if ma sens, ale porównywanie go z linią celu już nie. Przedstawiona analiza what-if to analiza wrażliwości dla jednej konkretnej zmiennej, przeprowadzona lokalnie dla jednego klienta. Pokazuje, jak zmieniałyby się PD klienta, gdybyśmy sztucznie zmieniali wartość jednej wybranej cechy.

Położenie punktu klienta na krzywej jest zaznaczone jako kropka na linii. Tam mamy przypisaną wartość zmiennej w problemie.

Wyróżniamy następujące sytuacje:

- jeśli krzywa rośnie → wyższa wartość cechy zwiększa PD,
- jeśli krzywa opada → wyższa wartość cechy poprawia ocenę klienta,
- jeśli krzywa jest płaska → zmienna słabo wpływa na ryzyko (lokalnie).

Na podstawie analizy odpowiedzi modelu można powiedzieć, że traktuje on tę zmienną w dużym zakresie monotonicznie.

Model zachowuje się logicznie: zawsze traktuje wzrost zysku operacyjnego jako czynnik obniżający ryzyko. Potwierdza to stabilność modelu – nie ma sytuacji, w której "za duży zysk" nagle zwiększyłby ryzyko (co byłoby błędem modelu). Krzywa ma kształt zbliżony do odwróconej litery "S" (typowe dla funkcji logistycznej/sigmoid w modelach ryzyka).

Wyróżniamy obszary na wykresie:

- Strefa Wysokiego Ryzyka (Lewa strona): Dla wartości ujemnych (poniżej -0.2), ryzyko jest wysokie i stabilne.
- Strefa Wrażliwości (Środek): W zakresie od ok. -0.2 do +0.2, krzywa gwałtownie spada. To jest strefa, w której walka się rozstrzyga. Każda mała poprawa zysku w tym przedziale drastycznie obniża ryzyko.
- Strefa Bezpieczeństwa (Prawa strona): Powyżej wartości +0.2, ryzyko spada i krzywa się wypłaszcza. Dalszy wzrost zysku już niewiele zmienia ("lepiej już być nie może").

8 Porównanie jakości i spójności wyjaśnień modelu black-box z modelem interpretowalnym

W tej sekcji porównamy ze sobą globalnie i lokalnie oba modele.

Przy porównaniu globalnym wybrano po 10 cech, które odpowiadały największej predykcji. Dla modelu XGBoost przy wyborze użyto metody SHAP, natomiast dla modelu regresji wyznaczono Współczynniki (Coefficients). W tabeli 7 zestawiono wybrane w ten sposób cechy dla każdego z modeli.

Tabela 10: Porównanie ważności cech: Model XGBoost vs Model Logistyczny

Lp.	Model XGBoost (SHAP)		Model Logistyczny (Coef)		
	Cecha	Waga	Cecha	Waga (Abs)	Współczynnik
0	wsk_sprzedaz_kap_obrotowy	0.0438	Rozliczenia_miedzyokresowe_krotkie	0.2664	-0.2664
1	Rozliczenia_miedzyokresowe_krotkie	0.0305	wsk_struktura_kap_wlasnego_2	0.2572	0.2572
2	wsk_koszty_przychody	0.0243	wsk_zysk_operacyjny_zob_1	0.1841	0.1841
3	wsk_zysk_operacyjny_zob_1	0.0206	wsk_sprzedaz_kap_obrotowy	0.1790	-0.1790
4	koszty_sprzedazy	0.0178	Zysk_netto	0.1258	-0.1258
5	wsk_rotacja_aktwow_1	0.0170	wsk_rotacja_wartosci_niewaterialnych	0.1143	-0.1143
6	wsk_rotacja_wartosci_niewaterialnych	0.0166	wsk_zysk_op_zobowiazania	0.0994	0.0994
7	wsk_zysk_op_zobowiazania	0.0161	Wartosc_firmy	0.0878	-0.0878
8	zysk_brutto	0.0143	wsk_rotacja_aktwow_1	0.0683	-0.0683
9	wsk_liczba_dni_istnienia	0.0123	wsk_amortyzacja	0.0678	-0.0678

Możemy wywnioskować, że modele mają różne „strategie poznawcze” — patrzą na problem zupełnie inaczej, co widać po innych rankingach cech i odmiennych kierunkach wpływu.

Regresja logistyczna:

- Preferuje mniejszy, bardziej „intuicyjny” zestaw cech.
- Najważniejsze cechy są stabilne i łatwe do interpretacji (spójne znaki, klarowne zależności).
- Wpływy cech są liniowe i każda cecha działa monotonicznie – to nadaje „porządek” globalnej interpretacji.

XGBoost:

- Ujawnia większe znaczenie innych cech niż regresja (często zupełnie inna kolejność oraz inny zestaw top cech).
- Uwzględnia nieliniowe zależności i interakcje — to powoduje, że hierarchia ważności jest bardziej złożona.
- SHAP dla XGBoost pokazuje zróżnicowane kierunki wpływu (czasem dodatnie i ujemne zależnie od wartości cechy).

Różnice lokalne zbadano dla dwóch klientów, dla których wcześniej podawano LIME w sekcji 6. W tabeli 8 pokazano ważność cech dla klienta granicznego, natomiast w tabeli 9 – dla klienta ryzykownego.

Tabela 11: Ważność cech dla klienta granicznego

Lp.	Model XGBoost (SHAP)		Model Logistyczny (Log-Odds)	
	Cecha	Wkład	Cecha	Wkład
1	wsk_zysk_operacyjny_zob_1	0.010972	wsk_ebitda_zobowiazan_odsetki_1	0.02
2	zysk_brutto	0.003469	wsk_zob_dlugoterminowe_aktywa_rzeczowe	0.02
3	wsk_ebitda_2	0.002236	wsk_koszt_dlugu_2	0.01
4	wsk_zadluzenia_dlugie	0.001993	wsk_ebitda_2	0.00
5	Kapitał_podstawowy	0.001543	wsk_struktura_majatku	-0.00

Wyjaśnienia decyzji są znacząco różne — oba modele wskazują inne „powody” dla oceny tego konkretnego klienta.

Spójność wyjaśnień:

- Regresja logistyczna: spójna globalnie i lokalnie (co ważne: lokalne wyjaśnienia wynikają bezpośrednio z globalnych).
- XGBoost: lokalnie może być spójny (SHAP działa dobrze), ale globalnie hierarchia cech inaczej wygląda niż lokalnie.

Tabela 12: Ważność cech dla klienta ryzykownego

Lp.	Model XGBoost (SHAP)		Model Logistyczny (Log-Odds)	
	Cecha	Wkład	Cecha	Wkład
1	Rozliczenia_miedzyokresowe_krotkie	-0.036889	Wartosc_firmy	-0.16
2	wsk_sprzedaz_kap_obrotowy	-0.030057	wsk_rotacja_wartosci_niewaterialnych	-0.25
3	wsk_koszty_przychody	-0.019666	Zysk_netto	-0.26
4	koszty_sprzedazy	-0.016703	wsk_sprzedaz_kap_obrotowy	-0.33
5	Zysk_netto	-0.013049	Rozliczenia_miedzyokresowe_krotkie	-0.54

Oba modele znacznie się różnią pod względami:

- Zestawu cech, które uważają za najważniejsze. Mają inne priorytety.
- Siłę wpływu cech. XGBoost ma często bardziej skrajne SHAP-y (nieliniowość i interakcje).
- Interpretacji tej samej osoby. Inne cechy zwiększają / zmniejszają ryzyko u wyszczególnionego klienta w zależności od modelu.

Zatem podsumowując:

Regresja = model interpretowalny i stabilny, ale uproszczony.

XGBoost = model dokładniejszy, ale jego „logika” jest dużo bardziej złożona.

9 Kalibracja, próg decyzyjny, mapowanie na ratingi - regresja logistyczna

Wstępna ocena Regresji Logistycznej wykazała stabilną zdolność rankowania ($AUC \approx 0.74$), lecz krytycznie wysokie wartości Log-Loss i Brier Score (≈ 0.60 i ≈ 0.20), co jest dowodem na silne nieskalibrowanie prawdopodobieństw (PD). Kolejne kroki miały na celu korektę tego problemu oraz dostosowanie progów decyzyjnych do wymagań biznesowych.

9.1 Ocena modelu

Aby ocenić skalibrowanie modelu wyznaczyliśmy dodatkowo ECE (Expected Calibration Error), krzywą reliability oraz histogram predykcji. Wykresy zostały przedstawione niżej, wraz z wynikami dla modelu po kalibracji.

- **ECE:** wyniosła 0.3370. Jest to wartość bardzo duża (dążymy do wartości poniżej 0.05 lub chociaż poniżej 0.1).
- **Krzywa reliability:** leży poniżej linii idealnej kalibracji - underconfidence (niedoszacowanie ryzyka) - model jest zbyt ostrożny.
- **Histogram predykcji:** Najwięcej obserwacji ma prognozowane ryzyko defaultu ok. 50%, czyli model jest bardzo niepewny. Nie potrafi on z dużą pewnością zidentyfikować ani klientów bardzo bezpiecznych, ani bardzo ryzykownych.

Potwierdzone zostały wcześniejsze wnioski, że kalibracja jest konieczna.

9.1.1 Dekompozycja Brier Score

Brier Score mierzy całkowity błąd kwadratowy prognoz probabilistycznych. Można go rozłożyć na trzy składniki:

- **Uncertainty (Niepewność):** Jest to najmniejszy możliwy błąd dla danego zbioru; zależy tylko od globalnej frekwencji defaultu (np. 4%).
- **Resolution (Rozdzielczość):** Mierzy zdolność modelu do rankowania klientów; im wyższa wartość, tym lepiej model rozróżnia grupy ryzyka.
- **Reliability Error (Nieskalibrowanie):** Mierzy, jak bardzo prognozy modelu są nieuczciwe (niezgodne z rzeczywistą frekwencją); jest to błąd, który usuwamy poprzez kalibrację.

Dekompozycja Brier Score przed kalibracją przedstawia się następująco:

- Brier Score: 0.206994
- Uncertainty: 0.054931
- Resolution: 0.003069
- Reliability Error: 0.154972

Otrzymaliśmy duży Brier_Score i Reliability_Error - model wymaga kalibracji

9.2 Kalibracja Prawdopodobieństw (PD)

9.2.1 Kalibracja lokalna (Platt)

W celu poprawy dopasowania predykcji modelu do rzeczywistego poziomu ryzyka najpierw zastosowaliśmy kalibrację lokalną metodą Platt (sigmoid). Zastosowanie tej metody jest uzasadnione dla modeli opartych na regresji logistycznej oraz przy liczności zbioru walidacyjnego poniżej 1000 obserwacji (w naszym przypadku: 600). Kalibrację przeprowadzono w trybie `cv="prefit"`, co umożliwiło wykorzystanie już wytrenowanego modelu.

9.2.2 Kalibracja globalna (Calibration-in-the-large)

W kolejnym kroku wykonaliśmy kalibrację globalną poprzez dopasowanie średniego poziomu PD do wartości docelowej równej 4%. Metoda polega na estymacji stałego przesunięcia (shift) w przestrzeni logitów, które dodaje się do wszystkich predykcji. Stała została obliczona na zbiorze walidacyjnym. Następnie przesunięcie zastosowano do zbiorów: treningowego, walidacyjnego i testowego.

9.3 Ocena jakości po kalibracji

Połączenie kalibracji lokalnej i globalnej znacząco poprawiło zgodność predykcji z obserwowaną szkodowością.

- Po transformacji średnia wartość PD na zbiorze walidacyjnym osiągnęła cel 4%.
- Wartość ECE uległa znaczącej poprawie, po kalibracji wynosi 0.0277


Dekompozycja Brier Score po kalibracji przedstawia się następująco:

- Brier Score: 0.052761
- Uncertainty: 0.054931
- Resolution: 0.003069
- Reliability Error: 0.001128

Niski błąd relibility oraz poprawiony Brier Score potwierdzają, że model po kalibracji generuje spójne i realistyczne prawdopodobieństwa defaultu.

Poniżej krzywa reliability oraz histogram predykcji (przed i po kalibracji) potwierdzają poprawę modelu

Rysunek 10: Diagnostyka Kalibracji Modelu Regresji Logistycznej



9.3.1 Stabilność per podgrupa

Przeprowadzono analizę stabilności kalibracji dla najważniejszych cech w podgrupach wyznaczonych na podstawie mediany każdej z kluczowych cech modelu. Test polegał na porównaniu średnich PD i błędu ECE w dwóch segmentach: poniżej i powyżej wartości mediany.

Model po kalibracji utrzymuje spójne poziomy PD w różnych podzbiorach danych, a wszystkie ECE pozostaje na akceptowalnym poziomie, co potwierdza stabilność kalibracji.

Tabela 13: Stabilność kalibracji w podgrupach (5 najważniejszych cech)

Cechy i podziały	Średnie PD	ECE
Rozliczenia_miedzyokresowe_krotkie ≤ 0.0000	0.0483	0.0335
Rozliczenia_miedzyokresowe_krotkie > 0.0000	0.0295	0.0341
wsk_struktura_kap_wlasnego.s_1 ≤ 0.6702	0.0473	0.0307
wsk_struktura_kap_wlasnego.s_1 > 0.6702	0.0327	0.0290
wsk_zysk_operacyjny_zob_2 ≤ 0.0523	0.0496	0.0417
wsk_zysk_operacyjny_zob_2 > 0.0523	0.0304	0.0250
wsk_koszty_przychody ≤ 0.9844	0.0269	0.0315
wsk_koszty_przychody > 0.9844	0.0531	0.0287
Zysk_netto ≤ 0.0000	0.0509	0.0417
Zysk_netto > 0.0000	0.0268	0.0151

9.4 Optymalizacja Progu Decyzyjnego

Standardowy próg 0.5 nie jest optymalny w kontekście niebalansowanych danych finansowych, ponieważ nie uwzględnia rzeczywistych kosztów błędów

Optymalny próg znajdujemy poprzez minimalizację oczekiwanych strat wynikających z typów błędów predykcyjnych :

- **False Negative (FN):** Najdroższy błąd - klient ryzykowny, przyjęty.
- **False Positive (FP):** Utrata potencjalnego zysku - klient bezpieczny, odrzucony

W przypadku tego projektu ustaliliśmy wysoki kosztu dla błędu FN ($15\times$ większego niż FP), co wymusiło przyjęcie bardzo niskiego progu decyzyjnego, aby zmaksymalizować czułość (Recall) i zminimalizować ryzyko kosztownych defaultów.

Ostateczny próg decyzyjny został ustalony na poziomie 0.035 (3.5%).



Rysunek 11

9.5 Mapowanie PD na Klasy Ratingowe

Końcowym etapem jest przekształcenie ciągłego wskaźnika ryzyka (Calibrated PD) w dyskretne klasy ratingowe.

9.5.1 Definicja Klas Ratingowych

Zdefiniowano 7 klas ratingowych (od AAA - najbezpieczniejsi klienci do CCC - najbardziej ryzykowni klienci) w oparciu o ustalone progi PD.

Tabela 14: Definicja Progi Klas Ratingowych

Klasa Ratingowa	Zakres PD (%)
AAA	[0.00% – 1.00%)
AA	[1.00% – 2.00%)
A	[2.00% – 5.00%)
BBB	[5.00% – 8.00%)
BB	[8.00% – 12.00%)
B	[12.00% – 20.00%)
CCC	[20.00% – 101.00%)


9.5.2 Rozkład Klientów i Weryfikacja Monotoniczności

Po zastosowaniu mapowania do kalibrowanych PD, zweryfikowano rozkład obserwacji w klasach oraz kluczowy wymóg **monotoniczności ryzyka** (tj. czy średnie PD rośnie wraz z pogarszaniem się ratingu).

Tabela 15: Liczba Klientów na Klasę Ratingową (LR) Tabela 16: Średnie PD na Klasę Ratingową (LR)

Rating	Liczba Obserwacji
AAA	96
AA	96
A	250
BBB	99
BB	38
B	17
CCC	4


Rating	Średnie PD
AAA	0.005686
AA	0.014477
A	0.034725
BBB	0.063189
BB	0.099241
B	0.144661
CCC	0.224098



Rysunek 12: Średnia PD per rating dla Regresji Logistycznej po kalibracji 4% .

9.5.3 Wnioski z Mapowania

- **Monotoniczność Spełniona:** Jak widać w tabeli 16 i na wykresie 12, **średnie PD konsekwentnie rośnie** z każdą kolejną, gorszą klasą ratingową (od AAA $\approx 0.57\%$ do CCC $\approx 22.41\%$). Kluczowy wymóg ratingowy został spełniony, co potwierdza, że model jest gotowy do użytku operacyjnego.
- **Rozkład Klientów:** Rozkład jest **naturalny**. Większość klientów trafiła do klas bezpiecznych (A i lepsze), a najmniejsza liczba obserwacji (**4**) trafiła do najwyższego ryzyka (CCC).



Rysunek 13

9.6 Ostateczna Ocena Jakości Modelu Regresji Logistycznej

Po zastosowaniu kalibracji i nowego progu decyzyjnego (0.035), metryki modelu uległy znacznej poprawie w kluczowych obszarach.

Tabela 17: Ostateczne Metryki Jakości Regresji Logistycznej (Po Kalibracji i Progu 0.038)

Metryka	Treningowy	Walidacyjny	Testowy
AUC/ROC	0.7414	0.7452	0.7471
PR-AUC	0.2034	0.1750	0.2661
KS	0.3506	0.4220	0.3772
Log-Loss (Skalibrowany)	0.2251	0.2060	0.2181
Brier Score (Skalibrowany)	0.0594	0.0528	0.0574
Accuracy	0.5433	0.5400	0.5517
Recall (Czułość)	0.8167	0.8857	0.7436
Precision (Precyzja)	0.1091	0.1023	0.1007

9.6.1 Wnioski Końcowe

- **Brak Overfittingu**, AUC jest stabilne na wszystkich trzech zbiorach. Model jest wiarygodny i dobrze uogólnia wiedzę na nowe dane.
- **Sukces Kalibracji**, Brier Score i Log-Loss są niskie na wszystkich zbiorach, co potwierdza, że kalibracja Platt + korekta 4% zadziałała stabilnie.

Optymalizacja kosztów:

- Wysoki Recall - model jest dobry w identyfikowaniu i łapaniu przypadków ryzyka (defaultu).
- Niskie Precision (kosztem wysokiego Recall) oznacza, że duży odsetek klientów sklasyfikowanych jako ryzykowni w rzeczywistości jest dobry. Jest to jednak akceptowalny kompromis, gdyż ustaliliśmy, że przyjęcie ryzykownego klienta jest dużo bardziej kosztowne, niż odrzucenie bezpiecznego.
- Dosyć niskie PR-AUC jest również konsekwencją minimalizacji kosztów oraz nierównowagi klas y.

10 Kalibracja, Próg Decyzyjny, Mapowanie na Ratingi - XGBoost

Podobnie jak w przypadku regresji logistycznej, metryki Log-Loss i Brier Score wskazały na silne nieskalibrowanie prognozowanych prawdopodobieństw defaultu (PD). W kolejnych krokach przeprowadziliśmy kalibrację oraz optymalizację progu decyzyjnego.

10.1 Ocena Modelu

Aby ocenić kalibrację modelu, wyznaczyliśmy ECE, krzywą reliability oraz histogram predykcji.

- **ECE:** Wyniosło **0.2615**. Jest to wartość wysoka (powyżej 0.1), ale wyraźnie niższa niż dla modelu Regresji Logistycznej (0.3370), co sugeruje nieco lepsze dopasowanie wyjściowe.
- **Krzywa Reliability:** Podobnie jak w przypadku Regresji, leży poniżej linii idealnej kalibracji (underconfidence) – model jest **zbyt ostrożny** i niedoszacowuje ryzyka.
- **Histogram Predykcji:** Lepiej skoncentrowany niż dla Regresji Logistycznej, z większością predykcji bliżej niskich wartości PD (ok. 10%-20%), ale nadal wskazuje na **niepewność** modelu, co potwierdza konieczność kalibracji.

10.1.1 Dekompozycja Brier Score

Rozkład Brier Score przed kalibracją potwierdza, że głównym problemem jest niedopasowanie prognoz (Reliability Error).

- Brier Score: 0.136431
- Uncertainty: 0.054931
- Resolution: 0.002514
- Reliability Error: 0.085398

Otrzymaliśmy duży Reliability Error – model wymaga kalibracji.

10.2 Kalibracja Prawdopodobieństw (PD)

10.2.1 Kalibracja lokalna (Isotonic Regression)

W celu poprawy lokalnego dopasowania predykcji do rzeczywistego ryzyka zastosowano **Kalibrację Izotoniczną** (Isotonic Regression). Metoda ta jest preferowana dla modeli nieliniowych.

10.2.2 Kalibracja globalna (Calibration-in-the-large)

Analogicznie do poprzedniego modelu, wykonano kalibrację globalną poprzez dopasowanie średniej wartości PD do docelowego poziomu **4%** na zbiorze walidacyjnym. Następnie stałe przesunięcie w przestrzeni logitów zostało zastosowane do wszystkich zbiorów danych.

10.3 Ocena Jakości Po Kalibracji

Połączenie Kalibracji Izotonicznej i kalibracji globalnej znacząco poprawiło model.


- Po transformacji średnia wartość PD na zbiorze walidacyjnym osiągnęła cel **4.00%**.
- Wartość ECE uległa znaczącej poprawie, po kalibracji wynosi zaledwie **0.0183**.

Dekompozycja Brier Score po kalibracji przedstawia się następująco:

- Brier Score: 0.050996
- Uncertainty: 0.054931
- Resolution: 0.004125
- Reliability Error: 0.001236

Niski Błąd Reliability oraz niski Brier Score potwierdzają, że model po kalibracji generuje spójne i realistyczne prawdopodobieństwa defaultu. Poniższe wykresy (krzywe Reliability i histogramy predykcji) potwierdzają znaczącą poprawę:

Rysunek 14: Diagnostyka Kalibracji Modelu XGBoost



10.3.1 Stabilność per Podgrupa

Analiza stabilności kalibracji (dla najważniejszych cech otrzymanych za pomocą *feature_importance* wykazała, że model utrzymuje spójne poziomy PD i akceptowalnie niskie ECE w różnych podgrupach danych (wyznaczonych na podstawie mediany cech).


Tabela 18: Stabilność kalibracji w podgrupach (5 najważniejszych cech - XGBoost)

Cechy i podziały	Średnie PD	ECE
wsk_koszty_przychody ≤ 0.9844	0.0259	0.0231
wsk_koszty_przychody > 0.9844	0.0541	0.0239
Rozliczenia_miedzyokresowe_krotkie ≤ 0.0000	0.0518	0.0213
Rozliczenia_miedzyokresowe_krotkie > 0.0000	0.0251	0.0236
wsk_rent_kapitalu ≤ 0.5238	0.0472	0.0262
wsk_rent_kapitalu > 0.5238	0.0328	0.0165
koszty_finansowe ≤ 1.8400	0.0479	0.0254
koszty_finansowe > 1.8400	0.0321	0.0179
wsk_zadluzenia_dlugie ≤ 0.0000	0.0449	0.0240
wsk_zadluzenia_dlugie > 0.0000	0.0237	0.0230

10.4 Optymalizacja Progu Decyzyjnego

Optymalizację progu decyzyjnego przeprowadzamy tak samo, jak w przypadku regresji logistycznej. Znajdujemy go poprzez minimalizację strat wynikających z błędów predykcyjnych (błąd FN ma koszt $15 \times$ większy niż FP). Zoptymalizowany próg decyzyjny ma za zadanie maksymalizować czułość (Recall).

Ostateczny, optymalny próg decyzyjny został ustalony na bardzo niskim poziomie **0.025 (2.5%)**.



Rysunek 15: Wykres optymalizacji progu decyzyjnego dla modelu XGBoost.

10.5 Mapowanie PD na Klasy Ratingowe

Przekształcenie ciągłego wskaźnika ryzyka (Calibrated PD) w dyskretne klasy ratingowe odbywa się przy użyciu tych samych zdefiniowanych progów PD co dla Regresji Logistycznej. Analogicznie definiujemy 7 klas ratingowych (od AAA do CCC):

10.5.1 Rozkład Klientów i Weryfikacja Monotoniczności

Tabela 19: Liczba Klientów na Klasę Ratingową (XGB)

Rating	Liczba Obserwacji
AAA	117
AA	111
A	217
BBB	127
BB	0
B	22
CCC	6

Tabela 20: Średnie PD na Klasę Ratingową (XGB)


Rating	Średnie PD
AAA	0.005596
AA	0.011811
A	0.030569
BBB	0.074676
BB	NaN
B	0.161382
CCC	0.394447

Rysunek 16: Średnia PD per rating dla Modelu XGBoost po kalibracji 4% .

10.5.2 Wnioski z Mapowania

- **Monotoniczność Spełniona:** Jak widać w tabeli 20 i na wykresie, **średnie PD konsekwentnie rośnie** z każdą gorszą klasą ratingową (od AAA $\approx 0.56\%$ do CCC $\approx 39.44\%$). Brak obserwacji w klasie BB nie wyklucza monotoniczności, a jedynie wskazuje, że model przewidział dla tych klientów wyższe PD, kwalifikując ich bezpośrednio do klasy B lub gorszej.
- **Rozkład Klientów:** Rozkład jest **naturalny**. Większość klientów trafiła do klas bezpiecznych (A i lepsze). Model XGBoost skierował nieco więcej klientów do klas większego ryzyka

niż Regresja Logistyczna.



Rysunek 17

10.6 Ostateczna Ocena Jakości Modelu XGBoost

Po kalibracji i przyjęciu progu decyzyjnego 0.025, metryki modelu przedstawiają się następująco:

Tabela 21: Ostateczne Metryki Jakości Modelu XGBoost (Po Kalibracji i Progu 0.025)

Metryka	Treningowy	Walidacyjny	Testowy
AUC/ROC	0.9349	0.7685	0.7399
PR-AUC	0.4966	0.1812	0.1774
KS	0.7708	0.4106	0.4063
Log-Loss (Skalibrowany)	0.1665	0.1959	0.2230
Brier Score (Skalibrowany)	0.0493	0.0510	0.0579
Accuracy	0.6556	0.6217	0.6200
Recall (Czułość)	1.0000	0.8000	0.7949
Precision (Precyzja)	0.1622	0.1129	0.1235

10.6.1 Wnioski Końcowe

- **Przeuczenie (Overfitting)** jest widoczne – model zbyt mocno dopasował się do danych treningowych, o czym świadczy duża różnica wartości AUC/ROC między zbiorem treningowym (0.9349) a walidacyjnym (0.7685) i testowym (0.7399). Niemniej jednak, model **dobrze uogólnia** wiedzę, ponieważ wyniki na zbiorze walidacyjnym i testowym są do siebie zbliżone i utrzymują się na dobrym poziomie.
- **Sukces Kalibracji** został potwierdzony – niskie wartości Brier Score i Log-Loss dla wszystkich zbiorów dowodzą, że kalibracja izotoniczna w połączeniu z korektą 4% zadziałały stabilnie i skutecznie.

Optymalizacja Kosztów:

- **Wysoki Recall (Czułość)** jest priorytetem. Na zbiorach walidacyjnym (**0.8000**) i testowym (**0.7949**) jest on wysoki, co oznacza, że model jest skuteczny w **identyfikowaniu i łapaniu przypadków ryzyka (defaultu)**, co było naszym głównym wymogiem biznesowym.
- **Niskie Precision** jest bezpośrednią konsekwencją przyjętej strategii minimalizacji kosztów.

- Nisko ustalony próg decyzyjny (**0.025**) oznacza, że model świadomie akceptuje klasyfikację wielu bezpiecznych klientów jako ryzykownych (False Positives), aby tylko nie dopuścić do kosztownego błędu False Negative
- Niskie PR-AUC jest również konsekwencją tego kompromisu oraz nierównowagi klas.

11 Końcowe wnioski

Głównym celem projektu było zaprojektowanie systemu oceny ryzyka kredytowego przedsiębiorstw, zrealizowanego poprzez budowę dwóch modeli: **Regresji Logistycznej** (model interpretowalny) oraz **XGBoost** (model black-box).

11.1 Porównanie Modeli i Jakości

- **Zdolność Rankowania (AUC/ROC):** Model XGBoost wykazał nieznacznie lepszą zdolność do rankowania na zbiorze walidacyjnym i testowym ($AUC \approx 0.74 - 0.77$) w porównaniu do Regresji Logistycznej (≈ 0.74).
- **Przeuczenie (Overfitting):** XGBoost wykazał silny overfitting, ze znaczną różnicą w AUC/ROC między zbiorem treningowym (≈ 0.93) a testowym (≈ 0.74). Regresja Logistyczna była modelem **stabilnym** i dobrze uogólnionym, bez oznak przeuczenia.
- **Sukces Kalibracji:** Oba modele, po zastosowaniu odpowiednich metod kalibracji lokalnej (Platt dla LR, Isotonic Regression dla XGBoost) oraz korekty globalnej do docelowego $PD = 4\%$, osiągnęły niski błąd nieskalibrowania (**Reliability Error** bliski 0) oraz niski **Brier Score**.
- **Optymalizacja Kosztów (Recall):** Ustalony priorytet biznesowy (wysoki koszt **False Negative**) wymusił przyjęcie bardzo niskich progów decyzyjnych (LR: 0.035; XGBoost: 0.025). Skutkowało to wysoką **Czułością (Recall)** na poziomie $\approx 0.74 - 0.88$ (LR) i $\approx 0.79 - 0.80$ (XGBoost).
- Ostatecznie, oba modele spełniają kluczowy wymóg monotoniczności średniego PD na klasę ratingową, po mapowaniu na 7 klas (AAA do CCC).

11.2 Interpretowalność i Wyjaśnialność

- **Regresja Logistyczna (Interpretowalność):** Oferuje **spójną i stabilną interpretację globalną** (Współczynniki) i **lokalną** (Dekompozycja Logitu), która jest zgodna ze strukturą modelu. Wykresy PDP/ICE potwierdzają intuicyjne zależności ekonomiczne. Wadą jest wykryty **brak monotoniczności** dla większości cech.
- **XGBoost (Wyjaśnialność Black-Box):** Wyjaśnialność osiągnięto za pomocą metod **model-agnostic** (**SHAP**, **LIME**, **What-if**). Analiza **SHAP** wskazała na **efektywność zarządzania kapitałem obrotowym** (`wsk_sprzedaz_kap_obrotowy`) jako absolutnie kluczowy predyktor. Model nauczył się nieliniowych zależności i interakcji, co zwiększyło zdolność predykcyjną.